数据科学与工程导论

Introduction to Data Science and Engineering

第2章
数据思维与问题求解

1 问题求解与思维方式

2 计算思维与数据思维

3 计算思维与数据思维实例

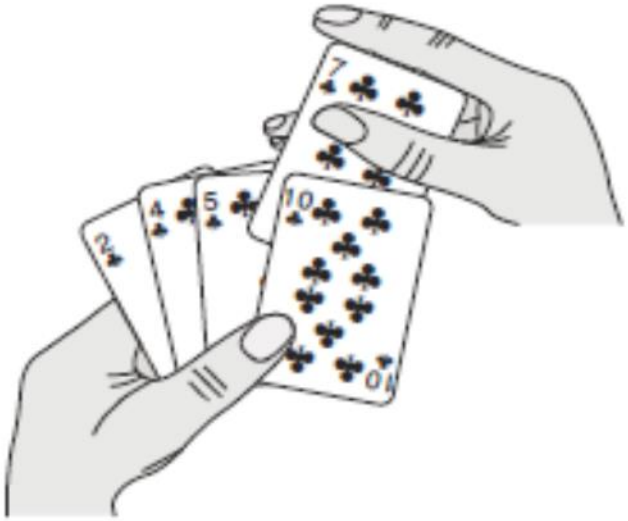

从玩牌的习惯性动作，
到计算机算法设计策略，
再到数据思维，
这条路并不遥远。

什么是思维

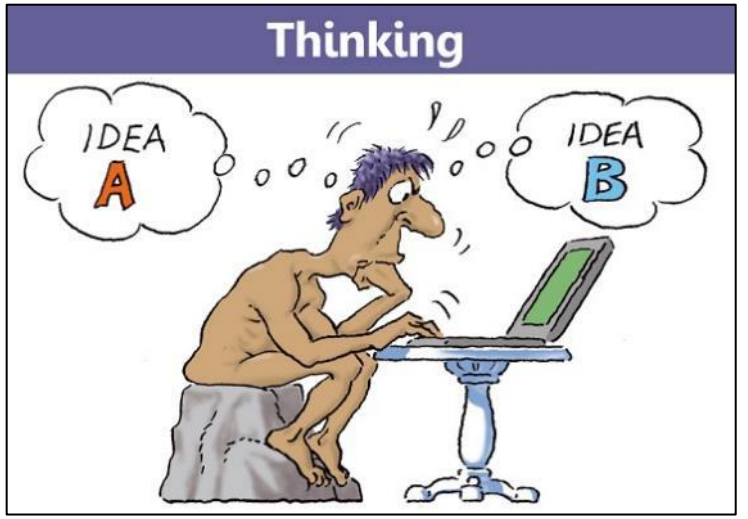

- 思维方式是人们大脑活动的内在程式，它对人们的言行起决定性作用。
- 思维方式决定行为结果，如果我们想在未来的学习工作上有所突破，一定要先在思维方式上有所提高。
- 思维方式决定了一个人的创新能力。

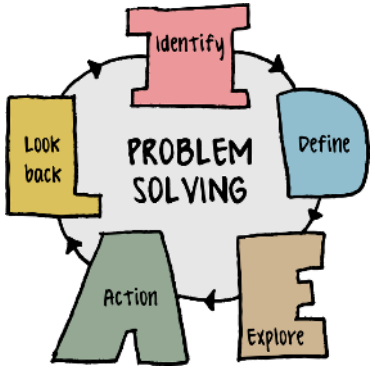

- 早在1972年，图灵奖得主Edsger Dijkstra就曾说：“我们所使用的工具影响着我们的思维方式和思维习惯，从而也深刻地影响着我们的思维能力”，这就是著名的“工具影响思维”的论点。

思维方式

直线思维

- 人们最常用、最简单、最本能的思维模式
- 用直线模式去思考问题：从当前点出发，用刚刚发生过的事情建立方向，用直线去预测结果
- 对于社会关系来说，运用直线思维可以形成简单的契约社会，人和人之间没有复杂的心理暗示
- 中国人很少采用直线思维思考社会问题，反而进行过度解读，形成了集体焦虑

逆向思维

- 对当前的状态进行反向思考。其目的是否定当前的状态，向相反的方向寻找目标
- 对于科学研究来说，逆向思维必不可少
- 逆向思维并不会持久存在，因为逆向思维的结果充满了风险

跳跃思维

- 不按部就班思考，间断性地向某个方向“跳起”的思维方式
- 跳跃思维可以跨过鸿沟，到达新的起点，在科研难题的突破上是非常有用的
- 跳跃思维要求人的大脑具有很强的活力、精力旺盛
- 这种能力的外在表现就是“异想天开”

常见的思维模式

归纳思维

- 是人处理外界信息的一种手段
- 利用归纳思维，能够在短时间内对复杂的信息建立各种模式，只要熟记几个简单的模式，就能掌握无穷多个可能的事实
- 很多人学习新知识很快，就是因为归纳思维运用得当。例如“举一反三”

并行思维

- 人的思维方式一般从一件事情开始，完成后再做另一件事情。这是自然选择，也是人的本能。
- 但是如果一个人负责一个团队，或者从事非常复杂的系统性问题研究时，必须学会同时思考几件事情，这就是并行思维。
- 我们并不是拥有多核的大脑，而是需要在不同的课题之间进行快速切换。

常见的思维模式

科学思维

通常是指理性认识及其过程，即经过感性阶段获得的大量材料，通过整理和改造，形成概念、判断和推理，以便反映事物的本质和规律。

科学思维是指人脑对自然界中事物的本质属性、内在规律及自然界中事物之间的联系和相互关系所做的有意识的、概括的、间接的和能动的反映，该反映以科学知识和经验为中介，体现为对多变量因果系统的信息加工过程。

简而言之，科学思维是人脑对科学信息的加工活动。

常见的思维模式

- Polya's Problem Solving Steps
  1. Understand the problem.
  2. Devise a plan for solving the problem.
  3. Carry out the plan.
  4. Evaluate the solution for accuracy and its potential as a tool for solving other problems.

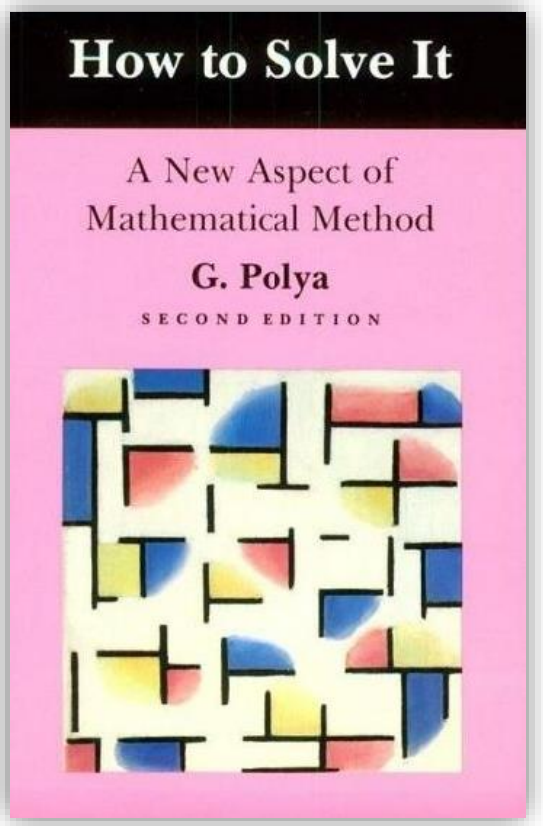

问题求解

第2章
数据思维与问题求解

1 问题求解与思维方式

2 **计算思维与数据思维**

3 计算思维与数据思维实例

- 计算思维就是运用计算机科学的基本概念进行问题求解、系统设计以及人类行为理解。
- 计算思维是一种普适的思维，是每个人的基本技能，正如印刷出版促进了阅读、写作和算术（英文称为3R）的传播。
- 计算思维强调一切皆可计算，从物理世界模拟到人类社会模拟，从人类社会模拟再到智能活动，都可认为是计算的某种形式。

周以真（Jeannette M. Wing）教授提出计算思维的理念

什么是计算思维

- 计算思维的本质是抽象和自动化。它反映了计算的根本问题，即什么能被有效地自动进行。
- 计算是抽象的自动执行，自动化需要某种计算机去解释抽象。从操作层面上讲，计算就是如何寻找一台计算机去求解问题，隐含地说就是要确定合适的抽象，选择合适的计算机去解释执行该抽象，后者就是自动化。

计算思维与计算机科学

分而治之

- 把数据、过程或问题分解成更小的、易于管理或解决的部分

模式识别

- 观察问题的模式、趋势和规律

抽象

- 识别模式形成背后的一般原理

算法设计

- 为解决某一类问题撰写一系列详细的步骤

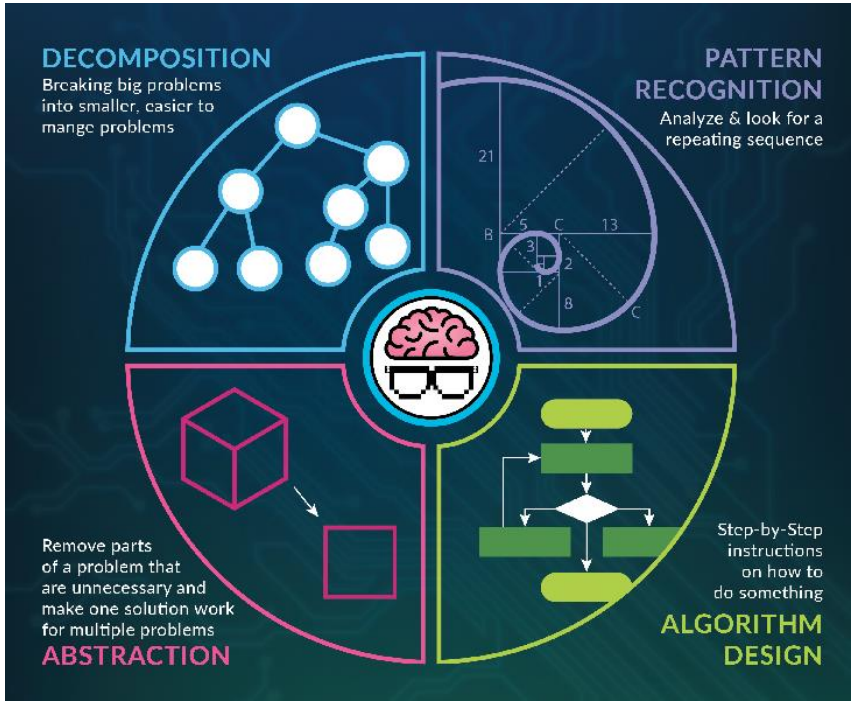

常见的计算思维方法

分而治之

- 分层思维帮助我们将复杂的问题拆解成小问题，把复杂的物体拆解成较轻易应付和理解的小物件，通过解决小问题而解决复杂的问题，使问题变得更加简单。
- 例：怎样制作汉堡包？我们可以将汉堡包分成几个部分：
  - Upper bun：最上层的圆面包
  - Lettuce：生菜
  - Tomato：西红柿
  - Cheese：奶酪
  - Beef patty：牛肉馅饼
  - Lower bun：下层的圆面包

常见的计算思维方法

模式识别

- 任何事物都有相似性，模式识别教会我们寻找到事物之间的共同特点，利用这些相同的规律，去解决问题。当我们把复杂的问题分层到小问题时，我们经常会在小问题中找到模式，这些模式在小问题当中有相似点。
- 从以往的经验中得到规律并且举一反三将它运用到其他的问题中，例如：

  ✓顺序模式是按顺序排列项目（所有物品）；

  ✓分组模式是将相似的项目(物品)分成一个组。

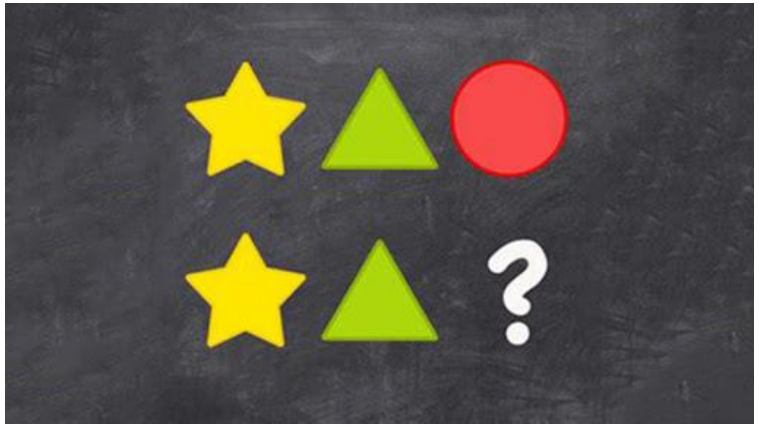

常见的计算思维方法

抽象

- 抽象化思维是将重要的信息提炼出来，去除次要信息的能力，掌握了抽象化的能力，我们就可以将一个解决方案应用于其他事物中，制定出解决方案的总体思路。

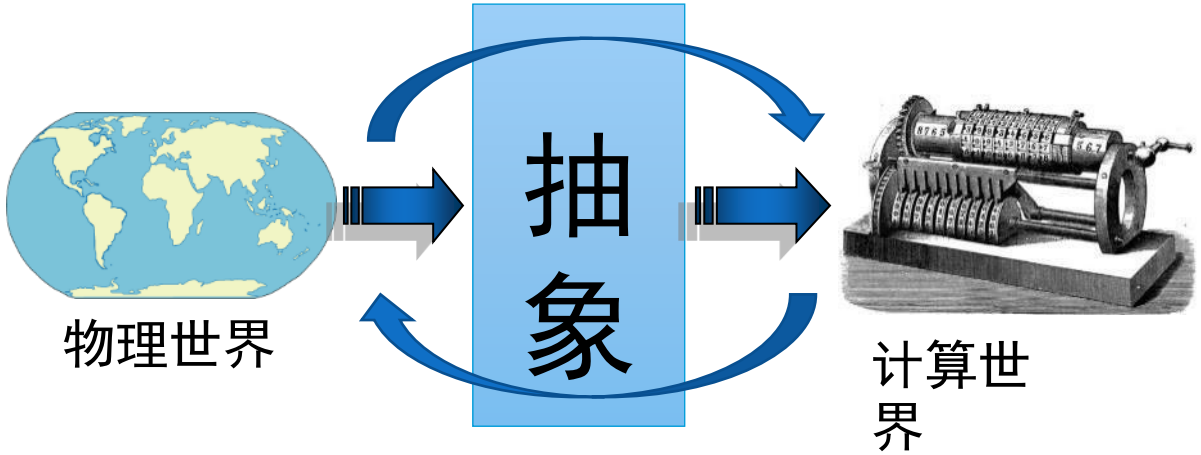

走向物理世界与计算世界的无缝连接

常见的计算思维方法

问题抽象

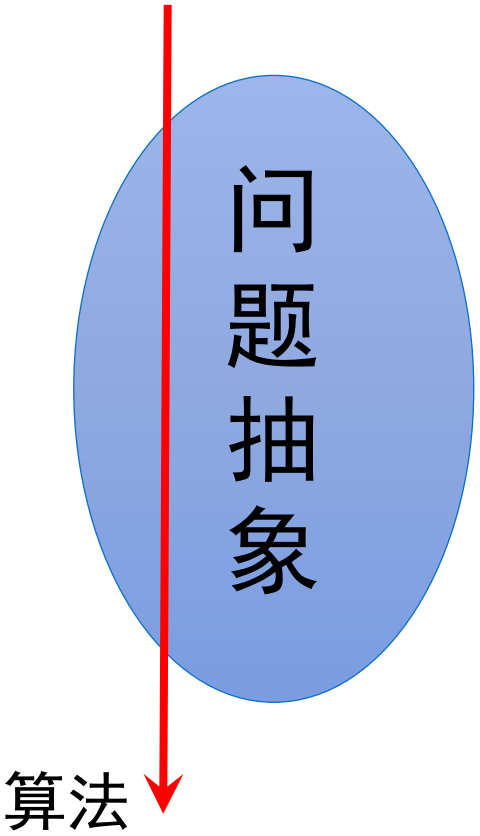

核心概念：

数学模型、表示、实现、转换

算法是计算思维的核心概念：

方法层: 算法

表示层: 编程

实现层: 机器

这差不多也就是计算机科学的主要内容了

常见的计算思维方法

问题抽象的分层映射

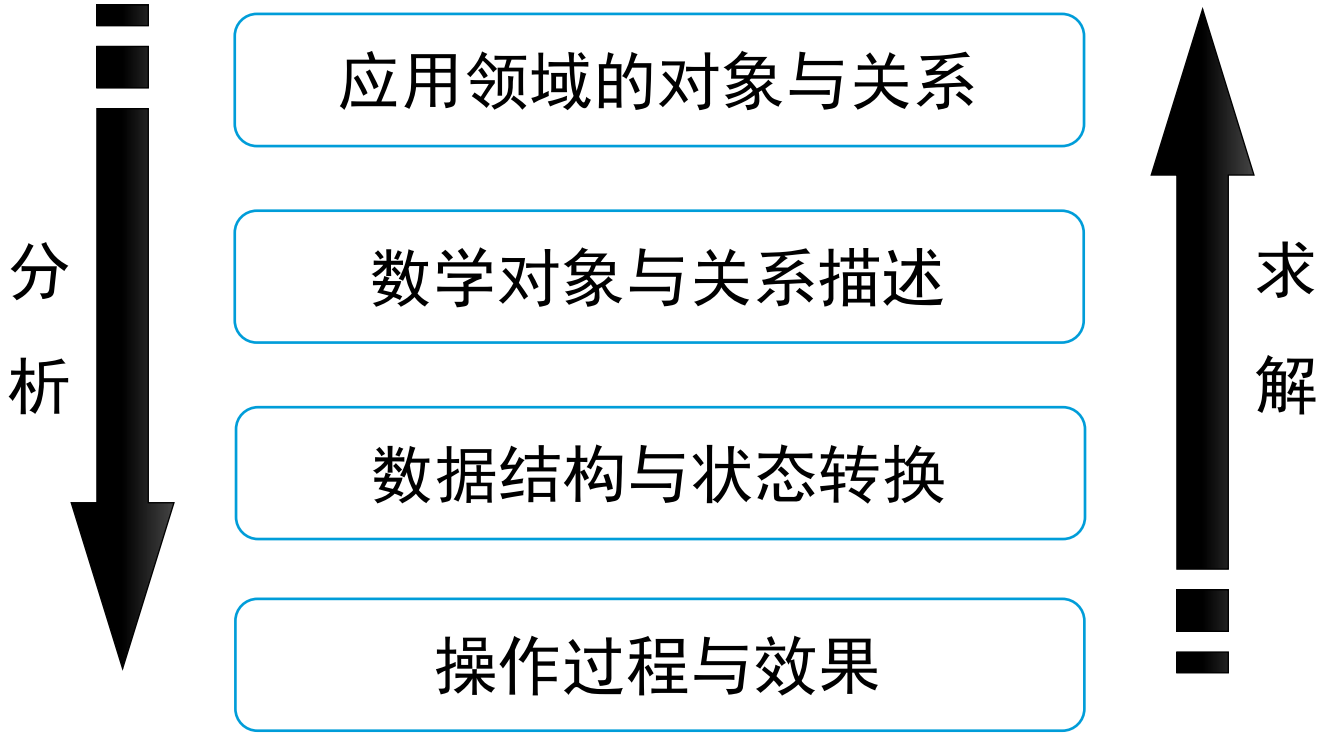

常见的计算思维方法

数据抽象

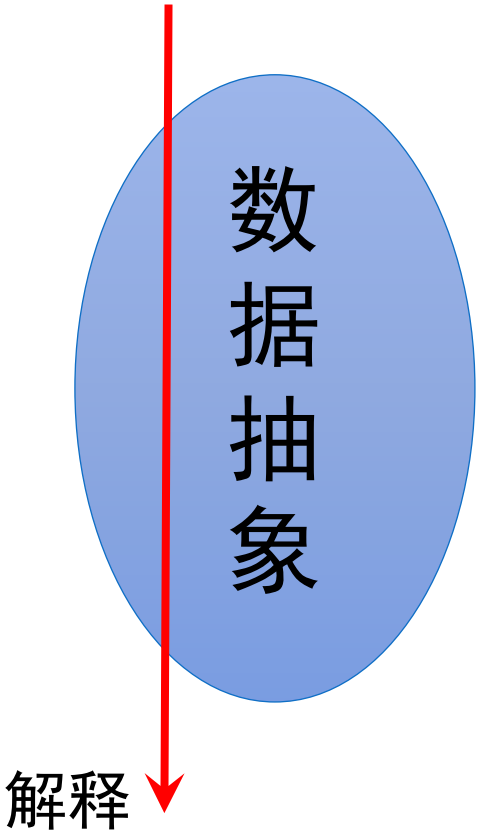

核心概念：

数据形态、数据组织、存储、检索与利用

常见的计算思维方法

数据抽象的分层映射

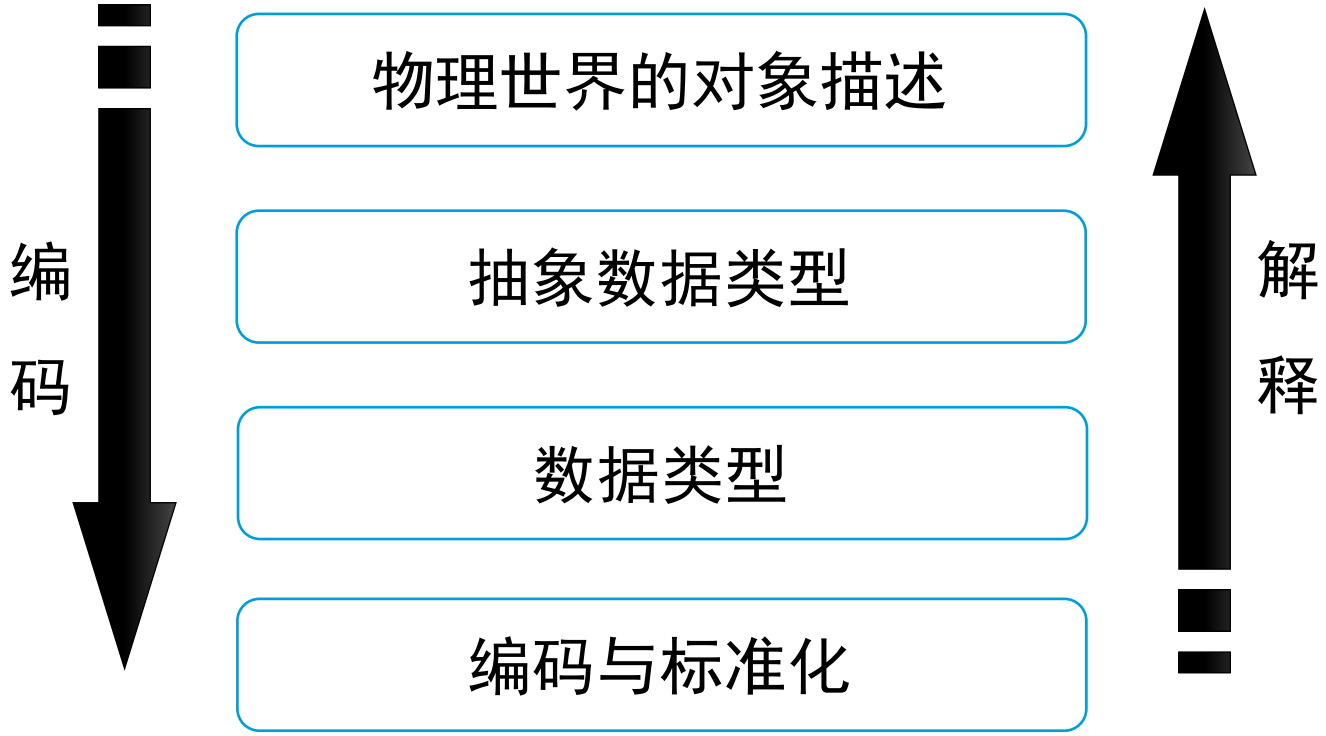

常见的计算思维方法

系统抽象

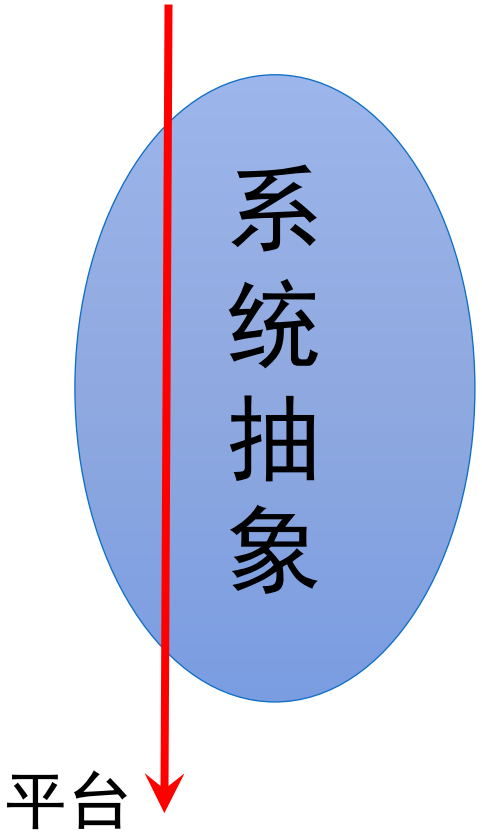

核心概念：

系统模型、功能逻辑、接口、实现

常见的计算思维方法

系统抽象的分层映射

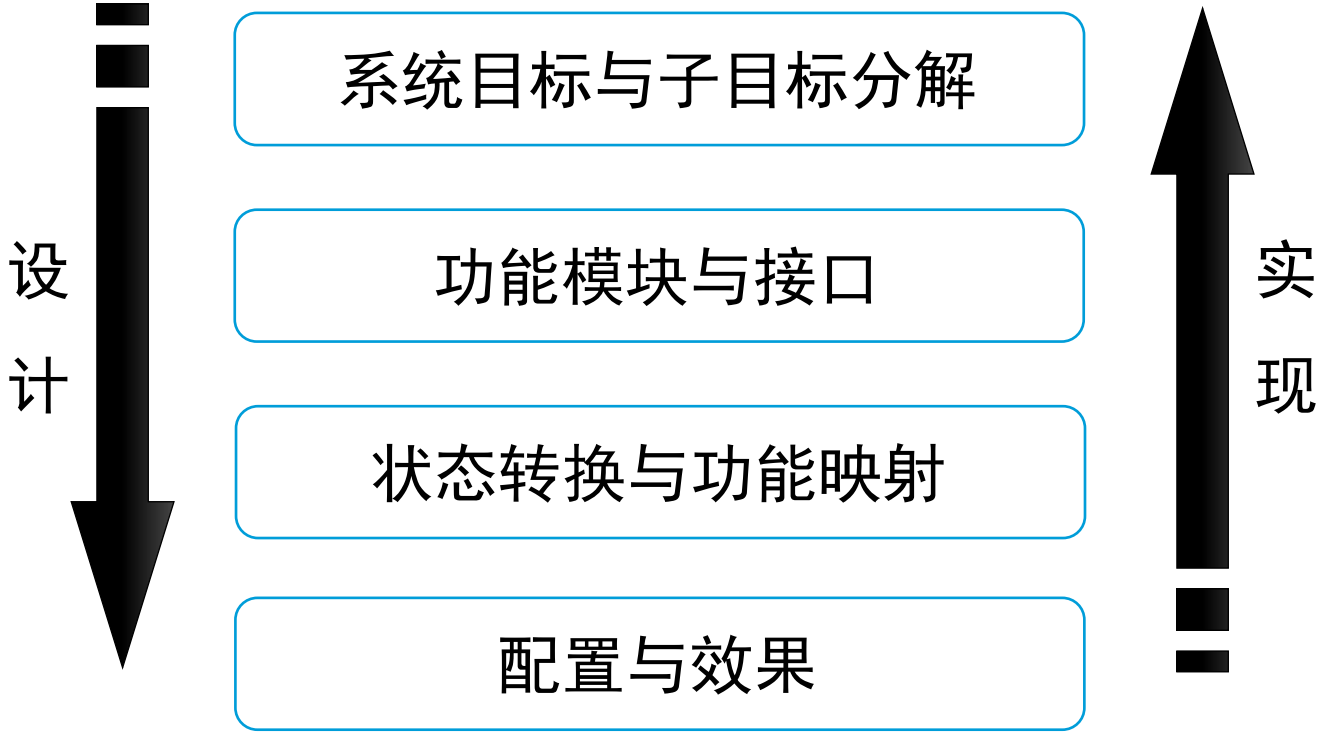

常见的计算思维方法

数据抽象

- 编码 → 数据记录 → 数据库

问题抽象

- 处理单个员工的相关记录
- 处理任意有限多个员工的不同记录（同样的处理方法）

系统抽象

- 应用界面：某种形式的“窗口”
- 逻辑电路支撑 → 系统软件支撑 → 数据库 → 应用程序支撑

企业的工资表处理

常见的计算思维方法

算法设计

- 一步一步解决问题的过程，按照的一定的顺序完成一个任务，同样的事情人人都会学习操作。
- An algorithm is an **ordered** set of **unambiguous**, **executable** steps that defines a **terminating** process.

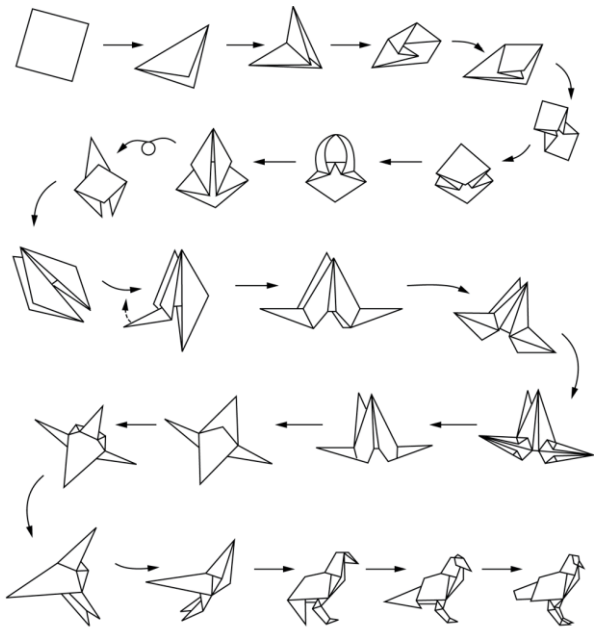

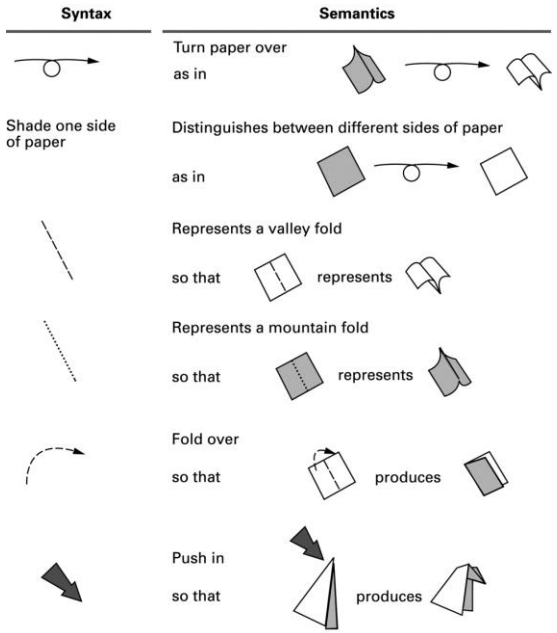

常见的计算思维方法

把实际问题抽象为数学问题，并建模，将人对问题的理解用数学语言描述出来

进行映射，把数学模型中的变量等用特定的符号代替，用符号一一对应数学模型中的变量和规则等

通过编程把解决问题的逻辑分析过程写成算法，把解题思路变成计算机指令，也就是算法

执行算法，进行求解，计算机根据算法，一步步完成相应指令，求出结果

运用计算思维进行问题求解

- **问题**：人、狼、羊、菜用一条只能同时载两位的小船渡河，“狼羊”、“羊菜”不能在无人在场时共处，当然只有人能驾船。
- **图模型**：顶点表示“原岸的状态”，两点之间有边当且仅当一次合理的渡河“操作”能够实现该状态的转变。
- 起始状态是“人狼羊菜”，结束状态是“空”，“允许状态”可以有10个。
- **问题的解**：找到一条从起始状态到结束状态的尽可能短的通路。

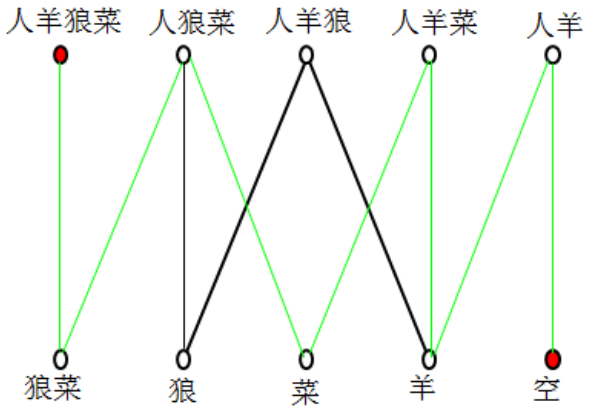

运用计算思维进行问题求解

- 上述关系可以用一个布尔矩阵表示：
  - 它也可以表示成一个“数”：10000000001110000000101000000000110……
  - 或者也可以表示成符号串：16#28#2#6#3#768#384#320#112#32

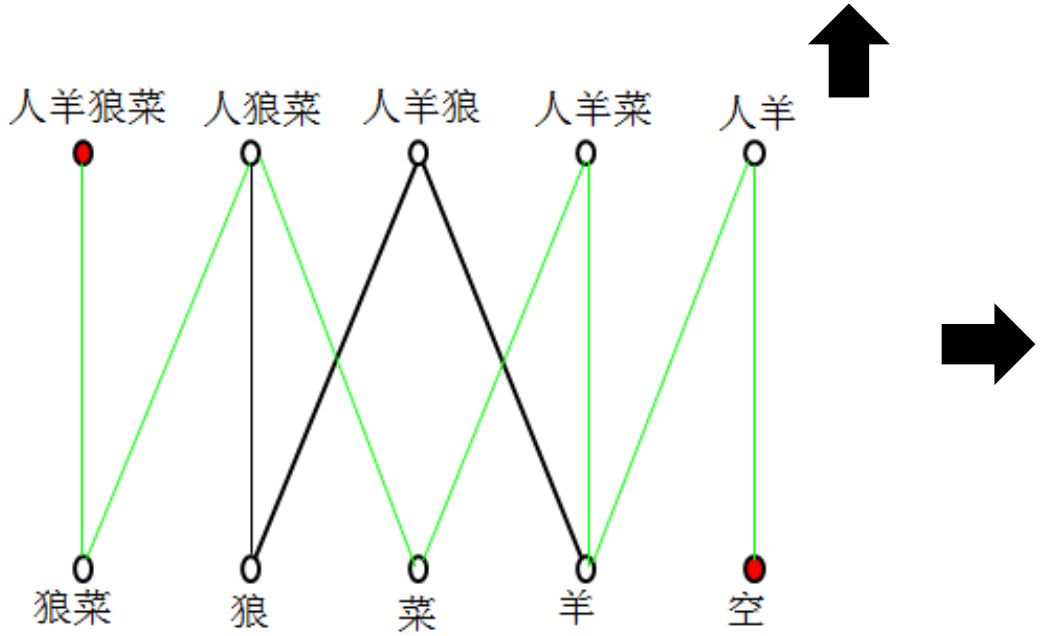

$$\begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

运用计算思维进行问题求解

方案1：
- 农夫带羊过河
- 农夫返回
- 农夫带狼过河
- 农夫带羊返回
- 农夫带菜过河
- 农夫返回
- 农夫带羊过河
- <结束>

方案2：
- 农夫带羊过河
- 农夫返回
- 农夫带菜过河
- 农夫带羊返回
- 农夫带狼过河
- 农夫返回
- 农夫带羊过河
- <结束>

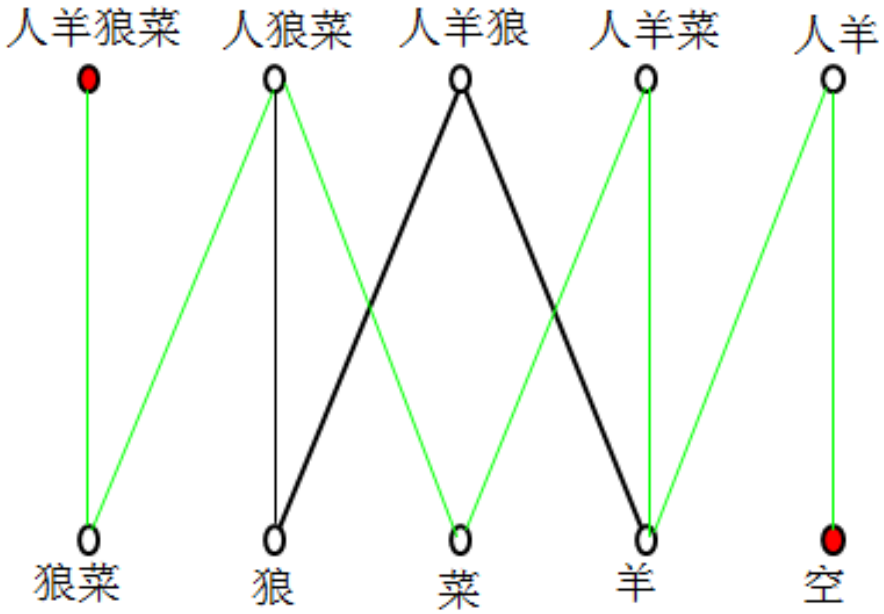

运用计算思维进行问题求解

- 数据思维是指获取数据、从数据中提取信息、论证结论可靠性等过程中表现出来的一种思维模式，对于人类提高认知起到巨大的作用，主要手段包括：
  - 计算方法：利用计算机和计算思维来进行数据的处理；
  - 统计方法：作为一种实证主义的方法，目的是从偶然性中发现必然性，对真理做出探究。
    - 统计学是检验理论与现实之间一致性的工作，统计学家设计收集数据的方法，提供数据特征的描述方法，并利用样本数据对总体特征做出估计、检验和预测。

什么是数据思维

- （例）行程设计：任意给出旅行的起点和终点，如何给出一个行程建议，使得在某些指标上“最短”？

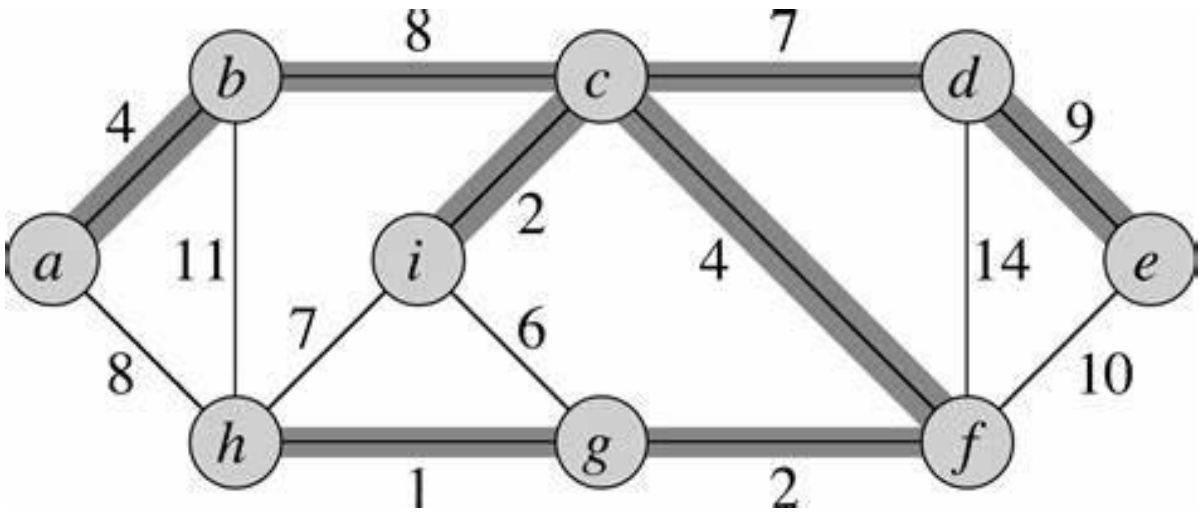

Dijkstra算法或者动态规划算法来求解，算法复杂度为$O(n^3)$

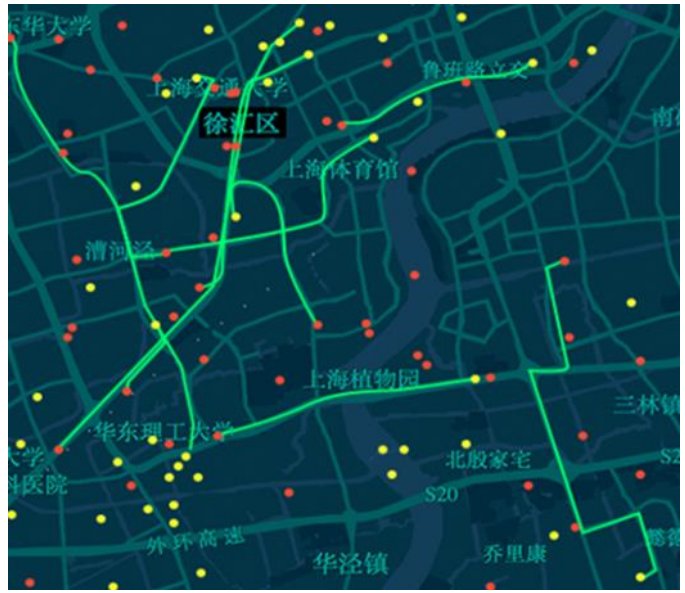

记录物理世界人们旅行的选择，构建数据模型，对最受欢迎的路线进行排序

什么是数据思维

- 数据思维，这个概念虽然很早就有，但直到近几年，随着大数据技术的飞速发展，重新又回到了思维认识的高度。
- 实际上，数据思维一直是人类的一种思维方式之一，而且应该比科学思维形成得更早，也更朴实。
- 科学思维应该是在数据思维之上产生的，而且科学思维中也包括了数据思维，如一些基于统计的学科，其实就是数据思维的体现和应用。

数据思维的历史

“统计学不止是一种方法或技术，还含有世界观的成分，它是看待世界上万事万物的一种方法。我们常讲某事从统计观点看如何如何，指的就是这个意思。但统计思想也有一个发展过程。因此统计思想（或观点）的养成，不单需要学习一些具体的知识，还有能够从发展的眼光，把这些知识连缀成一个有机的、清晰的途径，获得一种历史的厚重感。”

——陈希孺，《数理统计学简史》

统计思维，就是用统计学的世界观去构建框架，然后去解释这个世界。

数据思维与统计学

- 计算环境的三大变革：
  - 海量数据资源 – 无尽的宝藏
  - 拓展的无线网络 – 无限的舞台
  - 智能化的设计与生产能力 – 无边的法力
- 不管你是从事那个领域的工作，数据爆炸和计算环境的革命为你提供了无限的创新机遇，就靠数据思维来发现了。
- 数据 + 数据思维 + 计算环境 = 无限的可能

数据思维与计算环境

搜索引擎

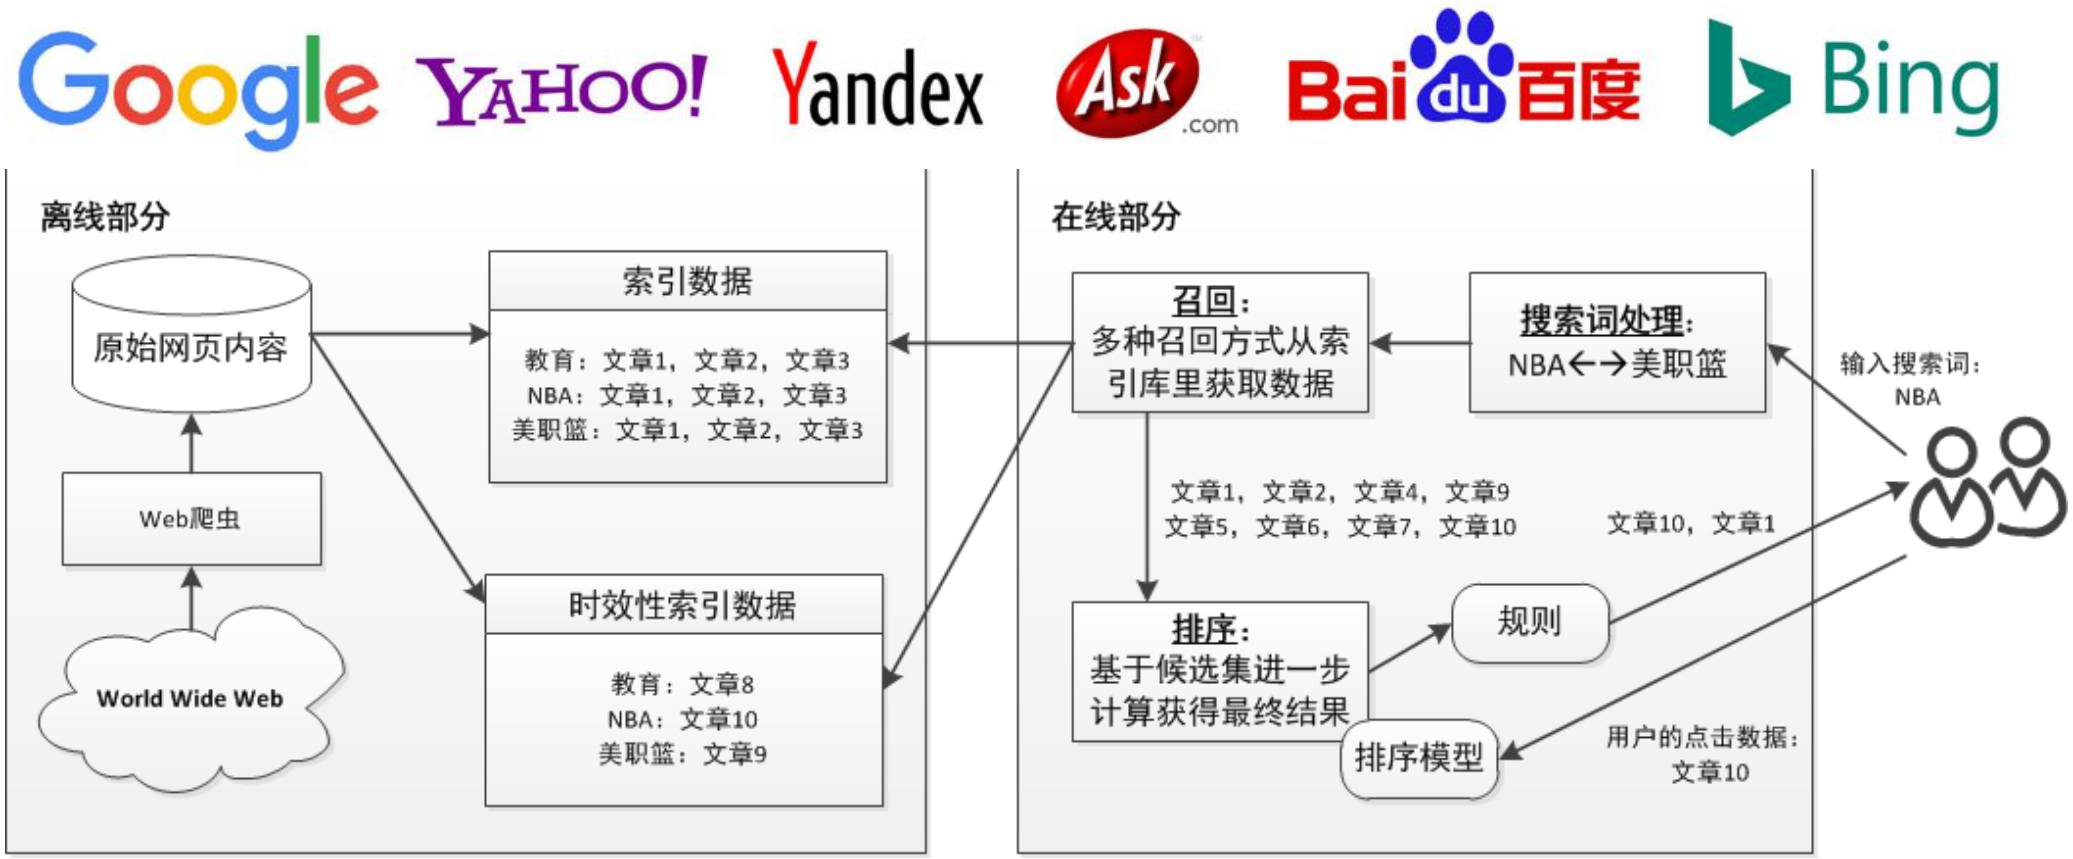
Google
YAHOO!
Yandex
Ask.com
Baidu 百度
Bing
离线部分
原始网页内容
Web爬虫
World Wide Web
索引数据
教育：文章1，文章2，文章3
NBA：文章1，文章2，文章3
美职篮：文章1，文章2，文章3
时效性索引数据
教育：文章8
NBA：文章10
美职篮：文章9
在线部分
召回：
多种召回方式从索引库里获取数据
搜索词处理：
NBA←→美职篮
输入搜索词：
NBA
文章1，文章2，文章4，文章9
文章5，文章6，文章7，文章10
文章10，文章1
排序：
基于候选集进一步计算获得最终结果
规则
排序模型
用户的点击数据：
文章10

推荐系统

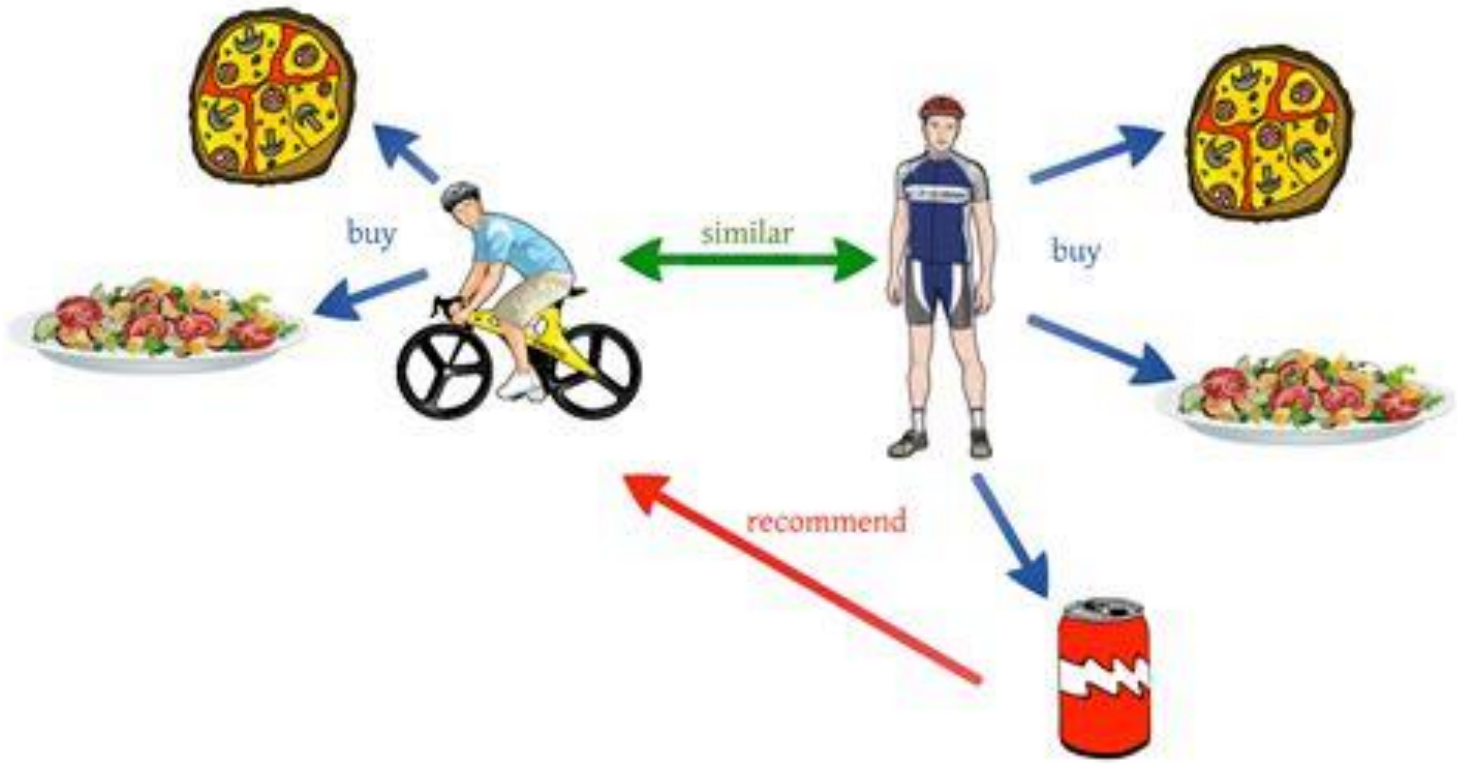

新闻推荐系统的架构

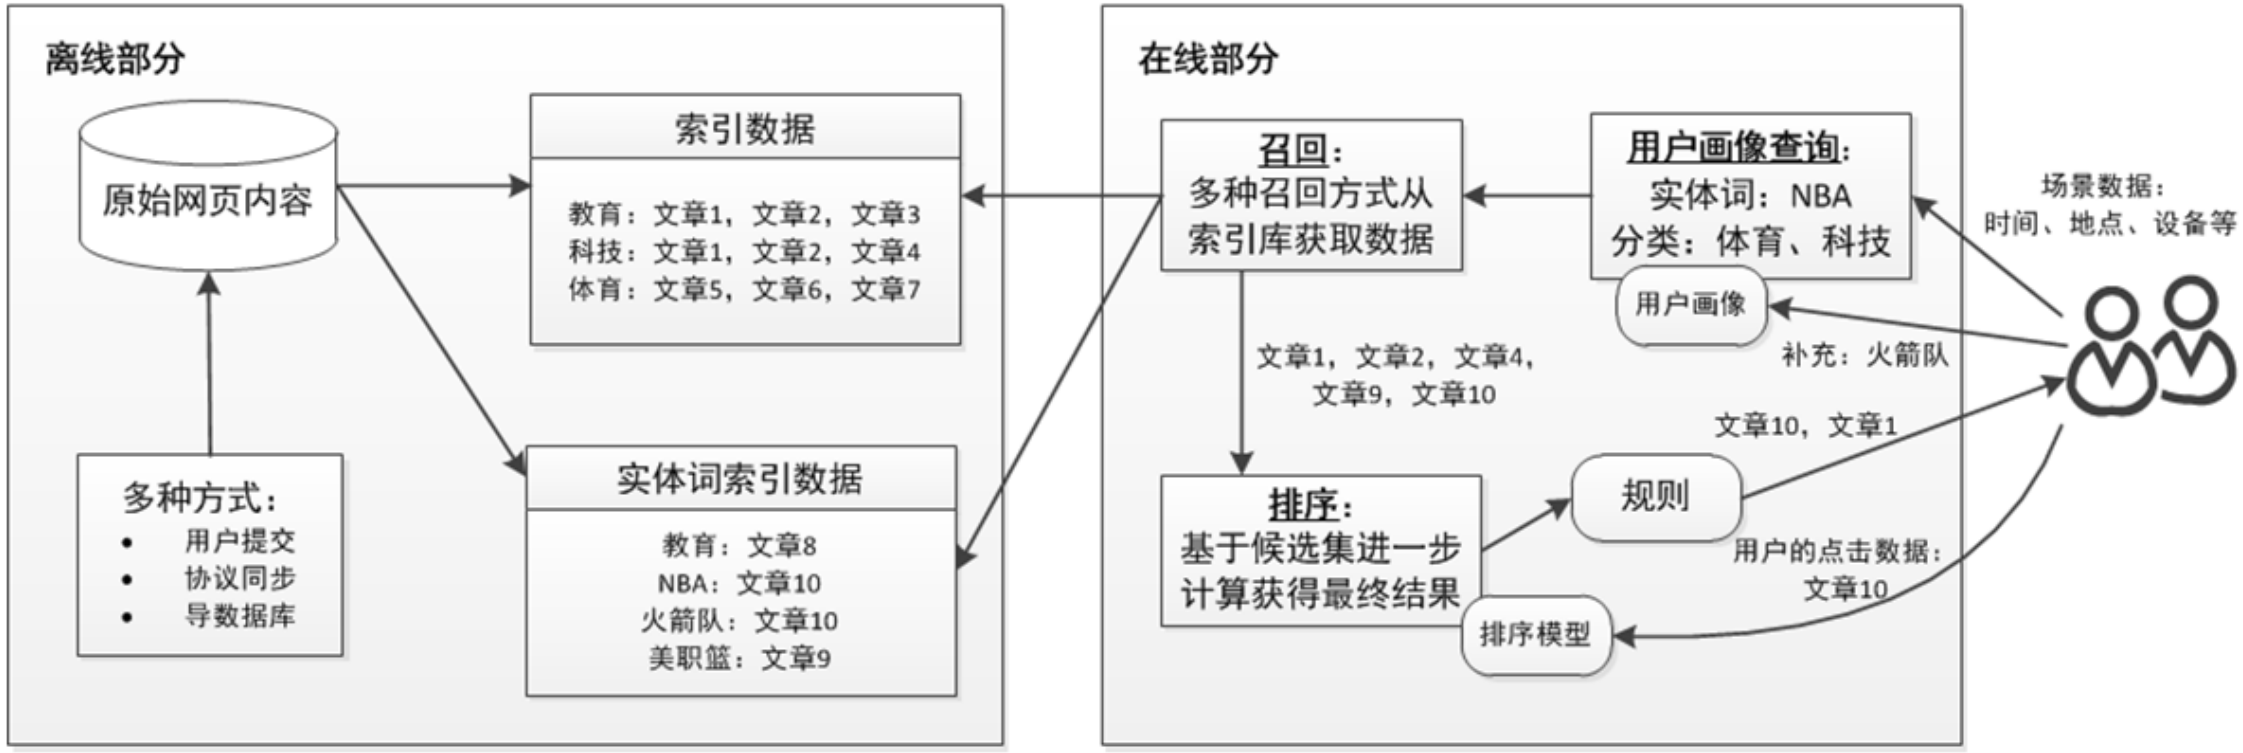
离线部分
原始网页内容
索引数据
教育：文章1，文章2，文章3
科技：文章1，文章2，文章4
体育：文章5，文章6，文章7
多种方式：
用户提交
协议同步
导数据库
实体词索引数据
教育：文章8
NBA：文章10
火箭队：文章10
美职篮：文章9
在线部分
召回：
多种召回方式从
索引库获取数据
用户画像查询：
实体词：NBA
分类：体育、科技
用户画像
场景数据：
时间、地点、设备等
补充：火箭队
文章1，文章2，文章4，
文章9，文章10
文章10，文章1
规则
排序：
基于候选集进一步
计算获得最终结果
用户的点击数据：
文章10
排序模型

第2章
数据思维与问题求解

1 问题求解与思维方式

2 计算思维与数据思维

3 **计算思维与数据思维实例**

- 从前有座山，山里有座庙，庙里有个老和尚，正在给小和尚讲故事呢！故事是这样的：从前有座山，山里有座庙，庙里有个老和尚，正在给小和尚讲故事呢！故事是这样的：从前有座山，……
- 递归（Recursion）是指在函数的定义中使用函数自身的方法。递归一词还较常用于描述以自相似方法重复事物的过程。

递归

- 斐波那契（Fibonacci）数列：[0,1,1,2,3,5,8,…]

- $$f(n)=\begin{cases}0, n=0\\ 1, n=1\\ f(n-1)+f(n-2), otherwise\end{cases}$$

```
def Fibonacci(n):
    if n == 0:
        return 0
    elif n == 1:
        return 1
    else:
        return Fibonacci(n - 1) + Fibonacci(n - 2)
```

递归

- 分治（Divide-and-Conquer）就是“分而治之”的意思，也就是说将一个复杂的大问题划分为若干相同或相似的、且相互独立的小问题，再把小问题继续划分为更小的问题，不断重复这个过程，直到“最小”的问题可以被直接地求解出来，然后将这些小问题的解层层合并，最终计算出原问题的解。

6 5 3 1 8 7 2 4

归并排序法

分治

- 上面实例的精妙有趣之处，就是它对于“算法”的研究，解决同一个问题可以设计出各种不同的算法，不是获得解就结束了，而是要进一步分析不同算法之间对程序执行效率的影响，然后选择最好的算法。
- “设计”就是算法研究中的最重要的问题，针对一个问题，设计出高效的算法，而不单单是解决给定的一个问题。
- 这就是计算之美！

计算思维小结

- 蒙特卡罗方法（Monte Carlo method），也称统计模拟方法，是1940年代中期由于科学技术的发展和电子计算机的发明，而提出的一种以概率统计理论为指导的数值计算方法。是指使用随机数（或更常见的伪随机数）来解决很多计算问题的方法。

蒙特卡洛方法

```python

# 蒙特卡洛法求Pi
import random
def Pi(times):
    sum = 0
    for i in range(times):
        x = random.random()
        y = random.random()
        d2 = x*x + y*y
        if d2 <= 1 :
            sum+=1
    return (sum/times*4)


times = 100000000
x = Pi(times)
print ("Pi = %.8f"%(x))
```

```
>>> # 蒙特卡洛法求Pi
... import random
>>> def Pi(times):
...     sum = 0
...     for i in range(times):
...         x = random.random()
...         y = random.random()
...         d2 = x*x + y*y
...         if d2 <= 1 :
...             sum+=1
...     return (sum/times*4)
...
>>>
>>> times = 100000000
>>> x = Pi(times)
>>> print ("Pi = %.8f"%(x))
Pi = 3.14172316
```

大约40秒以后

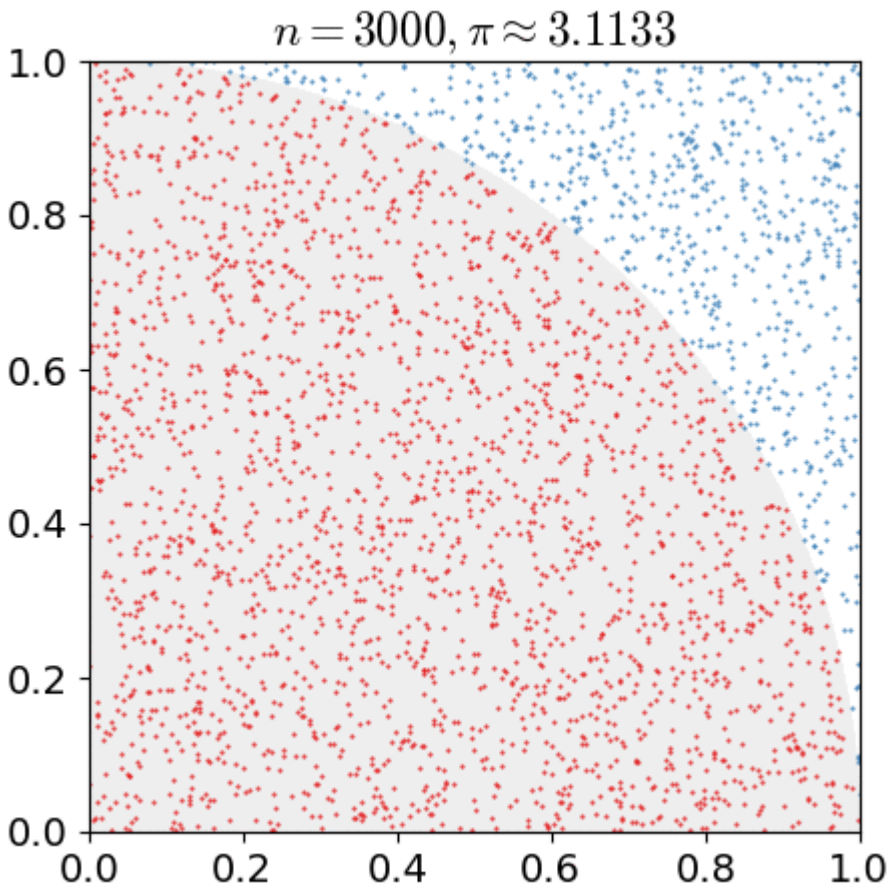

蒙特卡洛方法

- 从编程的角度来看，机器学习是一种能自动生成程序的特殊程序。

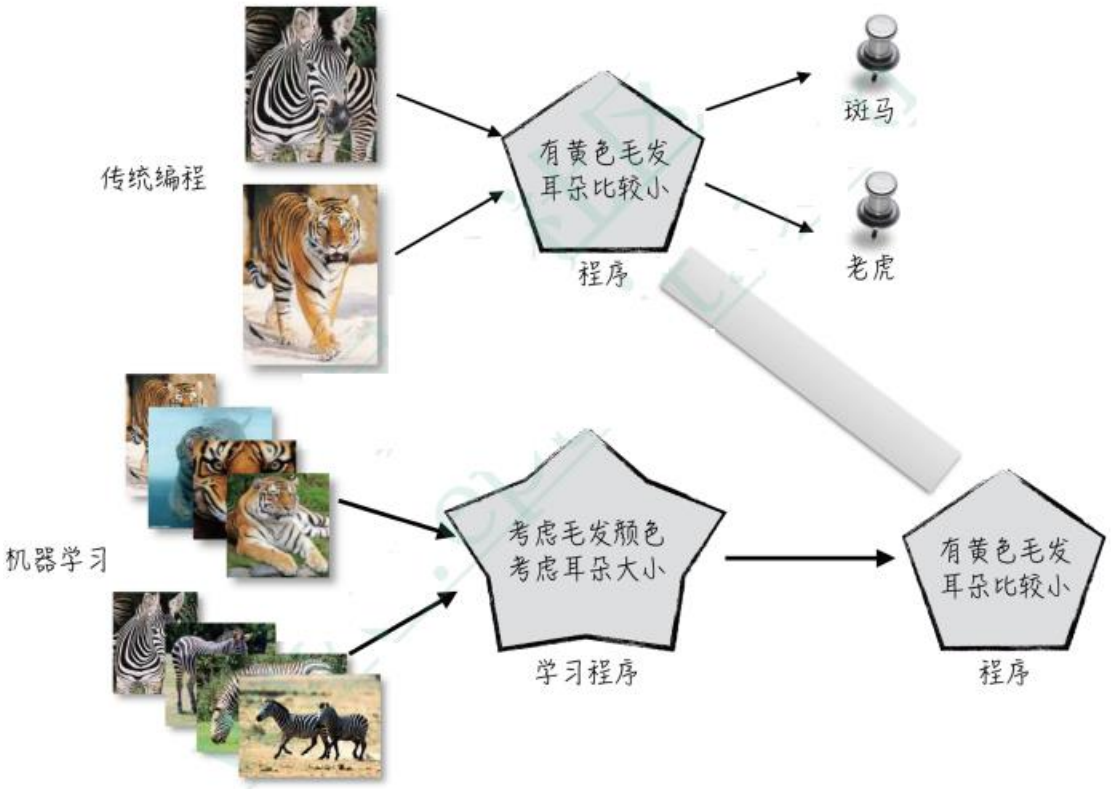

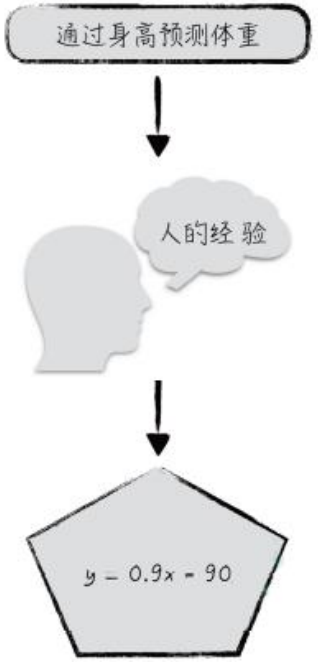

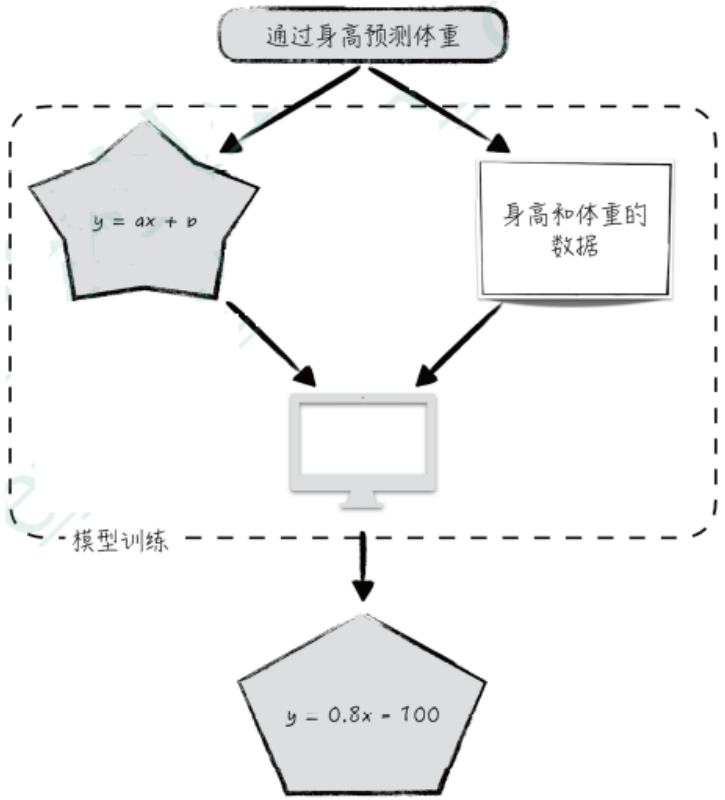

机器学习方法

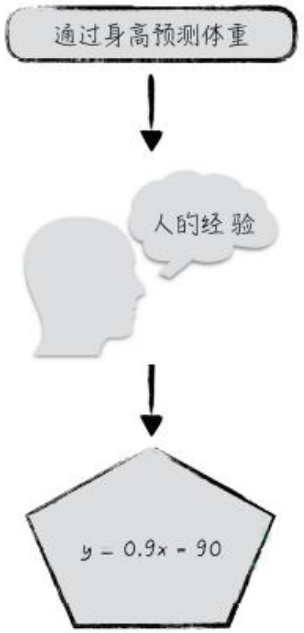

经验驱动的算法模型

数据驱动的算法模型

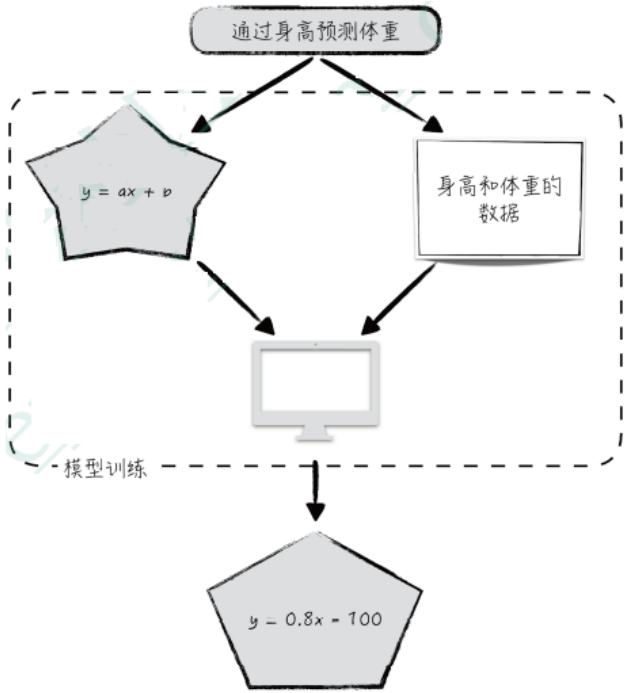

经验 → 算法模型 ← 数据

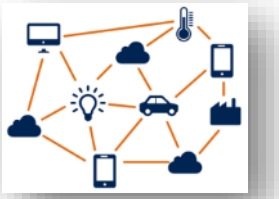

机器学习方法

- 上面实例的精妙有趣之处，就是在于以数据为中心或数据驱动的问题求解过程，传统算法无法或很难解决的问题，通过引入相关数据，往往就变得迎刃而解了。
- 这类问题除了需要考虑高效的算法之外，还要生产或采集到与之相关的关键数据，才能保证问题的高质量求解；
- 这就是计算与数据之美！

数据思维小结

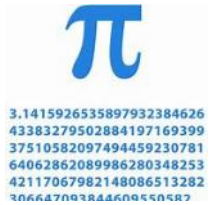

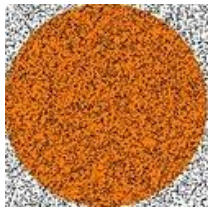

Machine Learning

（数据为中心的）问题求解

计算思维

数据思维

总结

第2章
数据思维与问题求解

1 问题求解与思维方式

2 计算思维与数据思维

3 计算思维与数据思维实例